

Rachunek macierzowy - mnożenie macierzy

March 11, 2023

1 Rachunek macierzowy - mnożenie macierzy

Wykonali: Alicja Niewiadomska, Paweł Kruczkiewicz

```
[ ]: import numpy as np
import matplotlib.pyplot as plt
import time
```

Wybrano temat nr 3, czyli *dla macierzy mniejszych lub równych $2^l \times 2^l$ mnożenie rekurencyjne metodą Bineta, dla większych - Strassena*.

Wybrane algorytmy macierzowe: 1. Mnożenie rekurencyjne metodą Bineta. 2. Mnożenie rekurencyjne metodą Strassena.

1.1 Pseudokod rozwiązania

Zakładamy, że dana macierz ma wymiary $2^k \times 2^k$.

Dane: - A, B - macierze kwadratowe o rozmiarze 2^k - k - wyżej wspomniany wykładnik - l - arbitralnie wybrana eksponenta wartości progowej dla danego algorytmu.

Wartość zwracana: C - wynikowa macierz kwadratowa o rozmiarze 2^k

```
def mat_mul(A, B, k, l):
    if k <= l:
        return binet_rec_mat_mul(A, B, k, l)
    else:
        return strass_mat_mul(A, B, k, l)
```

1.2 Kod algorytmu

1.2.1 Funkcje pomocnicze

```
[ ]: def split_matrix_in_quarters(A: np.array):
    half_i = A.shape[0] // 2
    return A[:half_i, :half_i], \
           A[:half_i, half_i:], \
           A[half_i:, :half_i], \
           A[half_i:, half_i:]

def join_matrices(A11, A12, A21, A22):
```

```

A1 = np.hstack((A11, A12))
A2 = np.hstack((A21, A22))
return np.vstack((A1, A2))

```

1.2.2 Algorytm rekurencyjny Bineta

```

[ ]: def binet_rec_mat_mul(A: np.array, B: np.array, k: int, l: int) -> np.array:
    if k == 0:
        return A*B

    rec_step = lambda A1, B1, A2, B2: mat_mul(A1, B1, k-1, l) + mat_mul(A2, B2,
↪k-1, l)

    A11, A12, A21, A22 = split_matrix_in_quarters(A)
    B11, B12, B21, B22 = split_matrix_in_quarters(B)

    C11 = rec_step(A11, B11, A12, B21)
    C12 = rec_step(A11, B12, A12, B22)
    C21 = rec_step(A21, B11, A22, B21)
    C22 = rec_step(A21, B12, A22, B22)

    return join_matrices(C11, C12, C21, C22)

```

1.2.3 Algorytm rekurencyjny Strassena

```

[ ]: def strassen_mat_mul(A: np.array, B: np.array, k: int, l: int) -> np.array:
    if k == 0:
        return A*B

    rec_step = lambda A1, B1: mat_mul(A1, B1, k-1, l)

    A11, A12, A21, A22 = split_matrix_in_quarters(A)
    B11, B12, B21, B22 = split_matrix_in_quarters(B)

    M1 = rec_step(A11 + A22, B11 + B22)
    M2 = rec_step(A21 + A22, B11)
    M3 = rec_step(A11, B12 - B22)
    M4 = rec_step(A22, B21 - B11)
    M5 = rec_step(A11 + A12, B22)
    M6 = rec_step(A21 - A11, B11 + B12)
    M7 = rec_step(A12 - A22, B21 + B22)

    C11 = M1 + M4 - M5 + M7
    C12 = M3 + M5
    C21 = M2 + M4
    C22 = M1 - M2 + M3 + M6

```

```
return join_matrices(C11, C12, C21, C22)
```

1.2.4 Algorytm końcowy

```
[ ]: def mat_mul(A, B, k, l):  
    if k <= l:  
        return binet_rec_mat_mul(A, B, k, l)  
    else:  
        return strassen_mat_mul(A, B, k, l)
```

1.3 Wykresy

Wybrane wielkości parametru l: 4, 6, 8

```
[ ]: l_values = [ 4, 6, 8 ]
```

```
[ ]: plt.rcParams["figure.figsize"] = [15, 10]  
plt.rcParams['font.size'] = 24  
plt.style.use('fivethirtyeight')
```

1.3.1 Wykres czasu mnożenia od wielkości macierzy

```
[ ]: k_values = np.arange(2, 9)  
num_range = 100  
  
### kod generujący czas  
  
def measure_mat_mul_time() -> np.array:  
    times = []  
  
    for i, k in enumerate(k_values):  
        times.append([])  
        for j, l in enumerate(l_values):  
            size = 2**k  
            A = np.random.randint(0, num_range, (size, size))  
            B = np.random.randint(0, num_range, (size, size))  
            print("Measuring: k=", k, " l=", l)  
  
            it = 10  
            start = time.time()  
            for _ in range(it):  
                mat_mul(A, B, k, l)  
            end = time.time()  
            res = (end-start)/it  
  
            times[i].append(res)
```

```

    return np.array(times)

### kod wykresu

def plot_time_results(times: np.array) -> None:
    x = k_values
    x_axis = np.arange(len(x))

    for i, l in enumerate(l_values):
        plt.bar(x_axis + 0.1*i, times[i], 0.1, label=l)

    plt.xticks(x_axis, x)
    plt.xlabel("k (matrix size 2^k)")
    plt.ylabel("Time in log scale [s]")
    plt.yscale("log")
    plt.title("Matrices multiplication performance")
    plt.legend(title="Parameter l")
    plt.show()

```

```

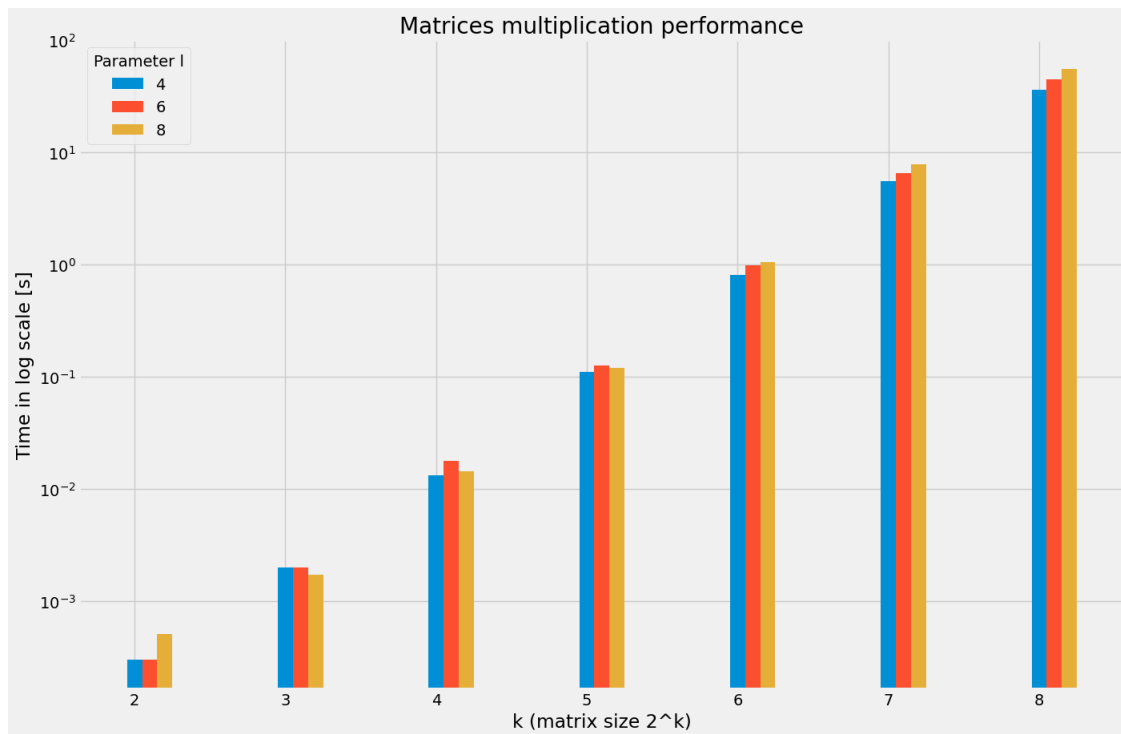
[ ]: times = measure_mat_mul_time()
    plot_time_results(times.T)

```

```

Measuring: k= 2  l= 4
Measuring: k= 2  l= 6
Measuring: k= 2  l= 8
Measuring: k= 3  l= 4
Measuring: k= 3  l= 6
Measuring: k= 3  l= 8
Measuring: k= 4  l= 4
Measuring: k= 4  l= 6
Measuring: k= 4  l= 8
Measuring: k= 5  l= 4
Measuring: k= 5  l= 6
Measuring: k= 5  l= 8
Measuring: k= 6  l= 4
Measuring: k= 6  l= 6
Measuring: k= 6  l= 8
Measuring: k= 7  l= 4
Measuring: k= 7  l= 6
Measuring: k= 7  l= 8
Measuring: k= 8  l= 4
Measuring: k= 8  l= 6
Measuring: k= 8  l= 8
(7, 3)

```



Powyższy wykres jasno pokazuje, że algorytm Strassena jest algorytmem wydajniejszym niż rekurencyjny algorytm Bineta dla każdego z przedstawionych przypadków. Można to wywnioskować po tym, że czas wykonania mnożenia tej samej macierzy jest mniejszy dla mniejszych wartości l (tj. gdy algorytm rekurencyjny stanowi mniejszą część obliczania macierzy).

1.3.2 Wykres wykonanych obliczeń zmiennoprzecinkowych w zależności od wielkości macierzy

```
[ ]: ### kod generujący liczbę obliczeń zmiennoprzecinkowych

def binet_rec_mat_mul_op_count(k: int, l: int) -> int:
    if k == 0:
        return 1 # multiplying matrices

    n = 2**(k-1)
    rec_step_op_count = 2 * mat_mul_op_count(k-1, l) + n*n

    C11_op_count = rec_step_op_count
    C12_op_count = rec_step_op_count
    C21_op_count = rec_step_op_count
    C22_op_count = rec_step_op_count

    return C11_op_count + C12_op_count + C21_op_count + C22_op_count
```

```

def strassen_mat_mul_op_count(k: int, l: int) -> int:
    if k == 0:
        return 1

    n = 2**k

    rec_step_op_count = mat_mul_op_count(k-1, l)

    M1_op_count = rec_step_op_count + 2*(n//2)*(n//2)
    M2_op_count = rec_step_op_count + (n//2)*(n//2)
    M3_op_count = rec_step_op_count + (n//2)*(n//2)
    M4_op_count = rec_step_op_count + (n//2)*(n//2)
    M5_op_count = rec_step_op_count + (n//2)*(n//2)
    M6_op_count = rec_step_op_count + 2*(n//2)*(n//2)
    M7_op_count = rec_step_op_count + 2*(n//2)*(n//2)

    C11_op_count = 3*(n//2)*(n//2)
    C12_op_count = (n//2)*(n//2)
    C21_op_count = (n//2)*(n//2)
    C22_op_count = 3*(n//2)*(n//2)

    return C11_op_count + C12_op_count + C21_op_count + C22_op_count +
    ↪M1_op_count + M2_op_count + M3_op_count + M4_op_count + M5_op_count +
    ↪M6_op_count + M7_op_count

### kod wykresu

```

```

[ ]: def mat_mul_op_count(k: int, l: int) -> int:
    if k <= 1:
        return binet_rec_mat_mul_op_count(k, l)
    else:
        return strassen_mat_mul_op_count(k, l)

```

```

[ ]: k_values = range(7, 20)
mat_mul_ops = np.array([[mat_mul_op_count(k, l) for l in l_values ] for k in
    ↪k_values])

def plot_ops_results(ops: np.array) -> None:
    x = k_values
    x_axis = np.arange(len(x))

    for i, l in enumerate(l_values):
        plt.bar(x_axis + 0.1*i, ops[i], 0.1, label=l)

    plt.xticks(x_axis, x)

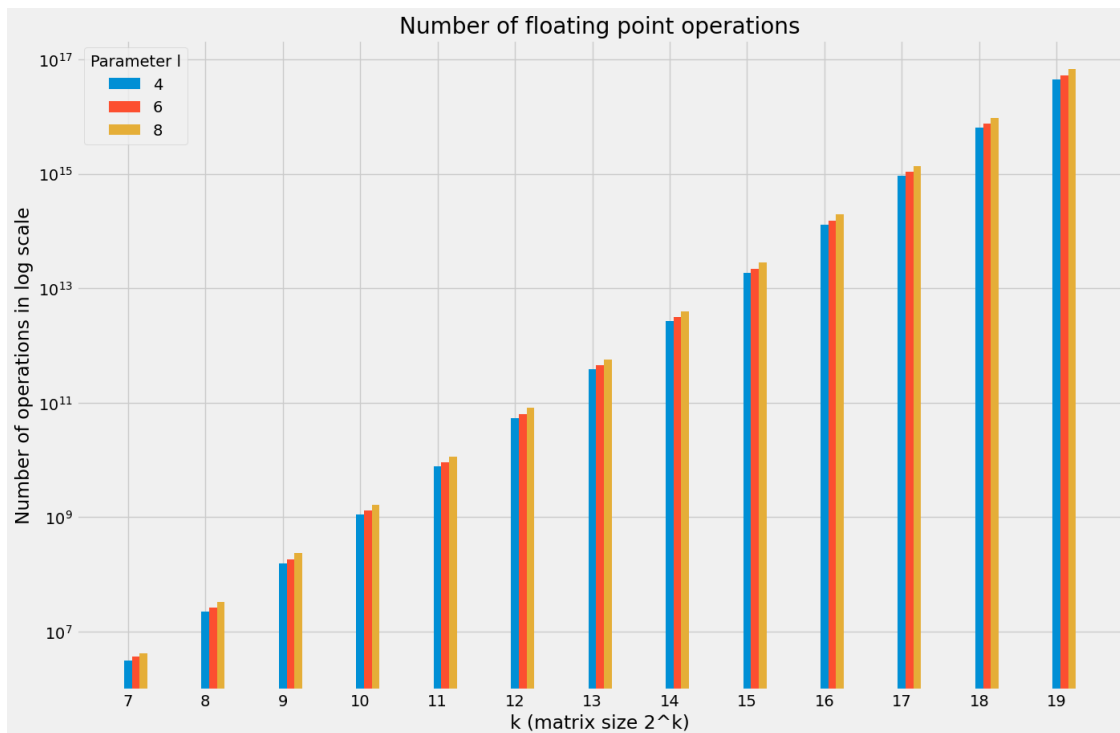
```

```
plt.xlabel("k (matrix size 2^k)")
plt.ylabel("Number of operations in log scale")
plt.yscale("log")
plt.title("Number of floating point operations")
plt.legend(title="Parameter l")
plt.show()
```

```
mat_mul_ops
```

```
[ ]: array([[      3150592,      3715072,      4177920],
 [      22349056,      26300416,      33488896],
 [      157623040,      185282560,      235601920],
 [      1108079872,      1301696512,      1653932032],
 [      7775433472,      9130749952,      11596398592],
 [      54503531776,      63990747136,      81250287616],
 [      381826712320,      448237219840,      569054003200],
 [      2673994945792,      3138868498432,      3984585981952],
 [      18722796458752,      21976911327232,      27896933711872],
 [      131078902564096,      153857706643456,      195297863335936],
 [      917629627360000,      1077081255915520,      1367162352762880],
 [      6423716629165312,      7539878029053952,      9570445706985472],
 [44967253354738432, 52780383153958912, 66994356899479552]],
      dtype=int64)
```

```
[ ]: plot_ops_results(mat_mul_ops.T)
```



Na powyższym wykresie widzimy, że w każdym przypadku mniej obliczeń jest dokonywanych, kiedy używamy algorytmu Strassena a nie algorytmu rekurencyjnego. Jest to zgodne z tym, co uzyskano na wykresie czasu od wielkości macierzy, tzn. uzyskujemy wyższą wydajność dla algorytmów, gdzie mnożenie Strassena stanowi większą część algorytmu niż algorytm rekurencyjny Bineta.

Należy pamiętać, że oś Y jest osią logarytmiczną. W rzeczywistości liczba obliczeń dla macierzy o rozmiarze 2^{19} byłaby niemal 1.5 raza większa dla algorytmu o $l=8$ niż dla analogicznej procedury o $l=4$.

1.4 Wnioski

W powyższym raporcie pokazano, że używanie algorytmu Strassena pozwala przyspieszyć mnożenie macierzy w przypadku ich dużych rozmiarów. Jest to algorytm wydajniejszy dla języka Python niż algorytm rekurencyjny.

Badania można rozszerzyć o mądrzejsze używanie pamięci, co potencjalnie pokazałoby korzyści z używania rekurencyjnego wzoru Bineta na mnożenie macierzy. Niestety, jest to niemożliwe w wybranym języku programowania.

[]: